ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

Nghiên cứu và Xây dựng Hệ thống Phát hiện Tin nhắn & Kịch bản Thao túng Tâm lý Lừa đảo nhắm vào Người cao tuổi tại Việt Nam

Vietnamese Elderly Scam Message & Psychological Manipulation Detection

Môn học: CS114 — Máy học • GVHD: ThS. Cáp Phạm Đình Thăng

NHÓM 10

Đặng Chí Thanh (25730067) • Bùi Thị Mỷ Cẩm (25730013) • Hoàng Cao Sơn (25730061)

KHOA KHOA HỌC MÁY TÍNH • TP. HỒ CHÍ MINH, THÁNG 09/2026

Lộ trình báo cáo

PHẦN 1

Giới thiệu

Bối cảnh, vấn đề và mục tiêu của nhóm

PHẦN 2

Dữ liệu & Phương pháp

2.193 mẫu, 4 nhóm bẫy tâm lý, pipeline tiền xử lý

PHẦN 3

Mô hình & Kết quả

So sánh 4 mô hình, ROC/PR, giải thích SHAP

PHẦN 4

Demo ứng dụng

Web Streamlit thân thiện với người cao tuổi

PHẦN 5

Kết luận & Hướng phát triển

Kết quả, hạn chế đã biết, PhoBERT và voice scam

PHỤ LỤC Q&A

Backup trả lời phản biện

Siêu tham số, Confusion Matrix, Learning Curves

Bối cảnh & Vấn đề

2.193

Mẫu tin nhắn thực tế

1.773 bình thường · 420 lừa đảo
100% có URL nguồn truy vết

4

Nhóm bẫy tâm lý

Quyền lực · Gia đình
Quà tặng · Dịch vụ công

0%

Văn bản do AI tự sinh

100% tin nhắn đời thực
Kiểm toán 7 tầng · 0% PII

"Tại sao người cao tuổi dễ bị lừa đảo qua tin nhắn hơn?"

Bài toán: phát hiện sớm tin nhắn thao túng tâm lý — ưu tiên không bỏ lọt (Recall), vì bỏ sót nguy hiểm hơn báo nhầm.

Mục tiêu & Đóng góp của Nhóm

So sánh 4 mô hình ML

- Naive Bayes · Random Forest
- XGBoost · SVM Linear
- Cùng tập test 439 mẫu (stratified 80/20)

Vượt chỉ tiêu kỹ thuật

- F1 ≥ 88% · Recall ≥ 92%
- Cả 4 mô hình đều đạt
- Ưu tiên Recall: bỏ lọt nguy hiểm hơn

Giải thích AI (XAI)

- SHAP Beeswarm trên XGBoost
- Top-20 từ khóa quan trọng đồng thuận
- Trả lời: vì sao tin này bị coi là lừa đảo?

Demo Streamlit cho người cao tuổi

- Chữ 100–150%, hotline 156/113 một chạm
- Dán tin nhắn → tự động phân tích
- 16/16 kiểm thử E2E Playwright

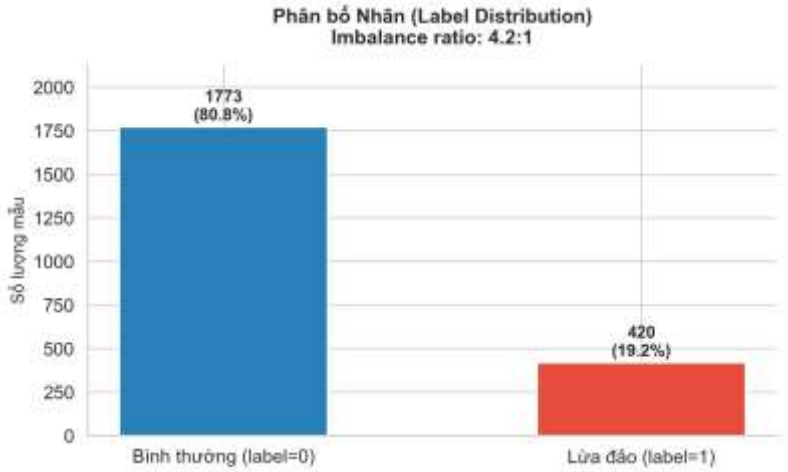
PHẦN 2

Dữ liệu & Phương pháp

- Đặc điểm tập dữ liệu: 2.193 mẫu thực tế có nguồn gốc kiểm chứng (Zero Synthetic Text)
- Phân loại 4 nhóm bẫy tâm lý phổ biến nhắm vào người cao tuổi tại Việt Nam
- Pipeline xử lý ngôn ngữ tự nhiên: Tiền xử lý tiếng Việt, TF-IDF 5.000 từ và 15 đặc trưng miền tâm lý
- Quy chuẩn Zero-Leakage: Phân lập tuyệt đối dữ liệu Train/Test trước mọi bước huấn luyện

Dataset: 2.193 Mẫu Thực Tế

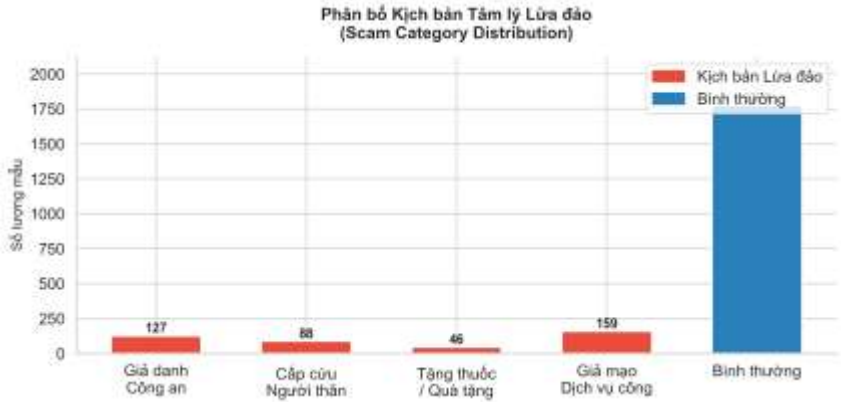
- 2.193 mẫu · Stratified Split 80/20 · nguồn [1], [2]
- Bình thường (label 0): 1.773 mẫu
- Lừa đảo (label 1): 420 mẫu — tỉ lệ 4.2:1
- Kiểm toán 7 tầng: 0% PII, 0% văn bản tổng hợp
- Tuyển chọn: Thanh 1.773 · Sơn 215 · Cẩm 205
- Train 1.754 · Test 439 (355 bình thường + 84 lừa đảo)



Phân bố nhãn (train + test)

Mất cân bằng 4.2:1 → đánh giá bằng Recall / F1 thay vì Accuracy; XGBoost bù bằng scale_pos_weight = 4.22

4 Nhóm Bẫy Tâm lý trong Dataset



Số mẫu lừa đảo theo nhóm bẫy tâm lý

Nhóm bẫy tâm lý	Mẫu	Kịch bản tiêu biểu
Đe dọa quyền lực	**127**	Giả cảnh sát / tòa án
Khẩn cấp gia đình	**88**	Con cháu tai nạn, cần tiền
Dụ dỗ quà tặng	**46**	Trúng thưởng, ưu đãi sức khỏe
Giả dịch vụ công	**159**	BHXH, điện lực giả mạo

Tổng 420 mẫu lừa đảo. Giả dịch vụ công (159) và Đe dọa quyền lực (127) chiếm 68%; nhóm Quà tặng (46) ít nhất nhưng tinh vi nhất — mỗi nhóm khai thác một điểm yếu tâm lý khác nhau.

Pipeline Tiền xử lý & Feature Engineering

1. Unicode NFC
NFC [3]
Dấu thanh [5]

→

2. Teencode
160 từ viết tắt
+ 22 mẫu leet

→

3. Tách từ (PyVi)
Ghép âm tiết
thành từ [4]

→

4. TF-IDF
5.000 đặc trưng
n-gram (1, 2) [6]

→

5. Đặc trưng phụ
15 đặc trưng:
URL, SĐT, OTP…

Không gian đặc trưng vector đầu vào: $\mathbf{x} = [\ \text{TF-IDF}(w_1, d), \ldots, \text{TF-IDF}(w_{5000}, d) \mid \text{f_meta}_1, \ldots, \text{f_meta}_{15}\ ]^T \in \mathbb{R}^{5015}$

• 5.000 đặc trưng từ vựng n-gram + 15 đặc trưng miền tâm lý (URL, OTP, SĐT...) • Naive Bayes chỉ dùng 5.000 TF-IDF

Zero-Leakage Protocol

1. Chia Train/Test (stratified 80/20) TRƯỚC mọi bước học từ dữ liệu
2. fit() TF-IDF & scaler chỉ trên X_train → transform() cho Train và Test

→ Vectorizer & scaler không bao giờ "nhìn thấy" tập Test

PHẦN 3

Mô hình & Kết quả

- Đánh giá và so sánh định lượng 4 mô hình: XGBoost, Random Forest, SVM Linear và Naive Bayes
- Phân tích hiệu năng phân lớp: Đường cong ROC Curves & Precision-Recall Curves (AUC ≥ 99%)
- Giải thích quyết định mô hình XAI bằng SHAP TreeExplainer: Top-20 đặc trưng phân định lừa đảo
- Thử nghiệm loại bỏ thẻ ẩn danh (Ablation Study): Chứng minh tính độc lập, không học vẹt nguồn

So sánh 4 Mô hình Machine Learning

Mô hình	Accuracy	Precision	Recall	F1	ROC-AUC
XGBoost (tốt nhất tổng thể)	**98.18%**	**93.18%**	**97.62%**	**95.35%**	99.84%
SVM Linear	97.95%	93.10%	96.43%	94.74%	**99.86%**
Random Forest	97.72%	91.11%	**97.62%**	94.25%	99.77%
Naive Bayes	95.44%	84.78%	92.86%	88.64%	99.11%

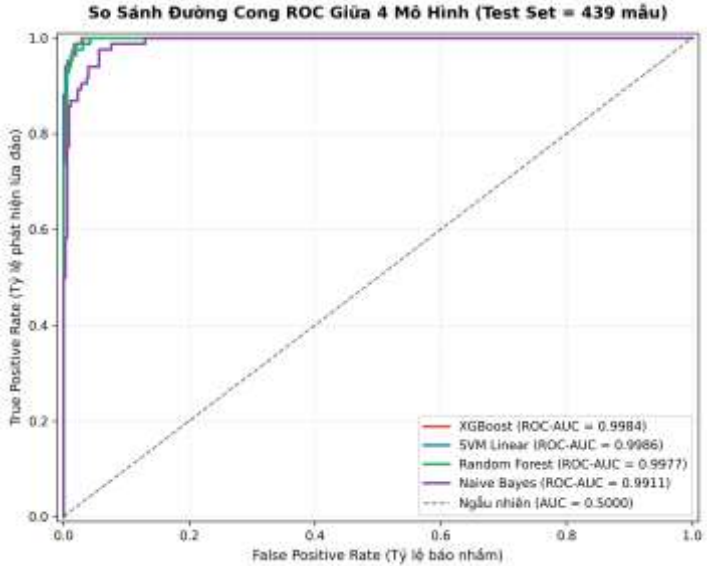
Kết luận: XGBoost — mô hình tốt nhất tổng thể

FN = 2: chỉ bỏ lọt 2/84 tin lừa đảo trong tập test (Recall 97.62%) · FP = 6

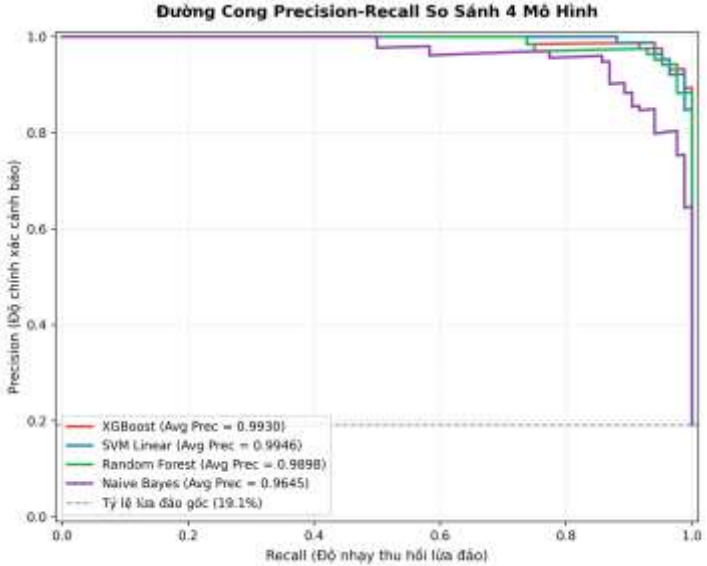
Cả 4 mô hình đều vượt chỉ tiêu F1 ≥ 88% và Recall ≥ 92% · Số in đậm xanh = tốt nhất theo cột

*Nguồn: models/*_metrics.json · tập test 439 mẫu (355 bình thường, 84 lừa đảo) · XGBoost [7], Random Forest [8], SVM [9] hiệu chỉnh xác suất [10], scikit-learn [11]*

ROC Curves & Precision-Recall Curves



(a) ROC Curves — tất cả AUC ≥ 99%

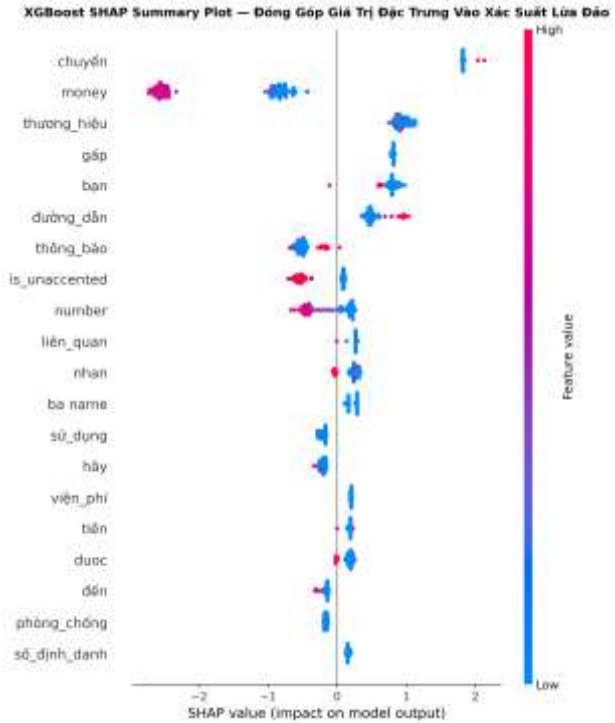


(b) Precision-Recall Curves — 4 mô hình

ROC-AUC của 4 mô hình: 99.11% – 99.86% → cả 4 tách lớp rất tốt; khác biệt nằm ở FN/FP và Precision.

Giải thích Mô hình — SHAP Analysis (XAI)

- SHAP TreeExplainer trên XGBoost [12], [13] — không phải "hộp đen"
- Top-20 từ khóa quan trọng (đồng thuận 4 mô hình):
  - Thiên về lừa đảo: mày, gấp, viện_phí, thuế, số_định_danh (100% tin chứa từ này là lừa đảo)
  - Thiên về bình thường: money, number, time, liên_hệ 198, soạn, viettel (≤ 2% là lừa đảo)
- Lưu ý: money, number, time, đường_dẫn… là thẻ ẩn danh có sẵn trong bộ dữ liệu gốc
- Bỏ 453 đặc trưng chứa thẻ này: F1 XGBoost 95.35% → 94.25%, Recall giữ 97.62%



(c) Phân bố tác động SHAP (TreeExplainer) trên mô hình XGBoost

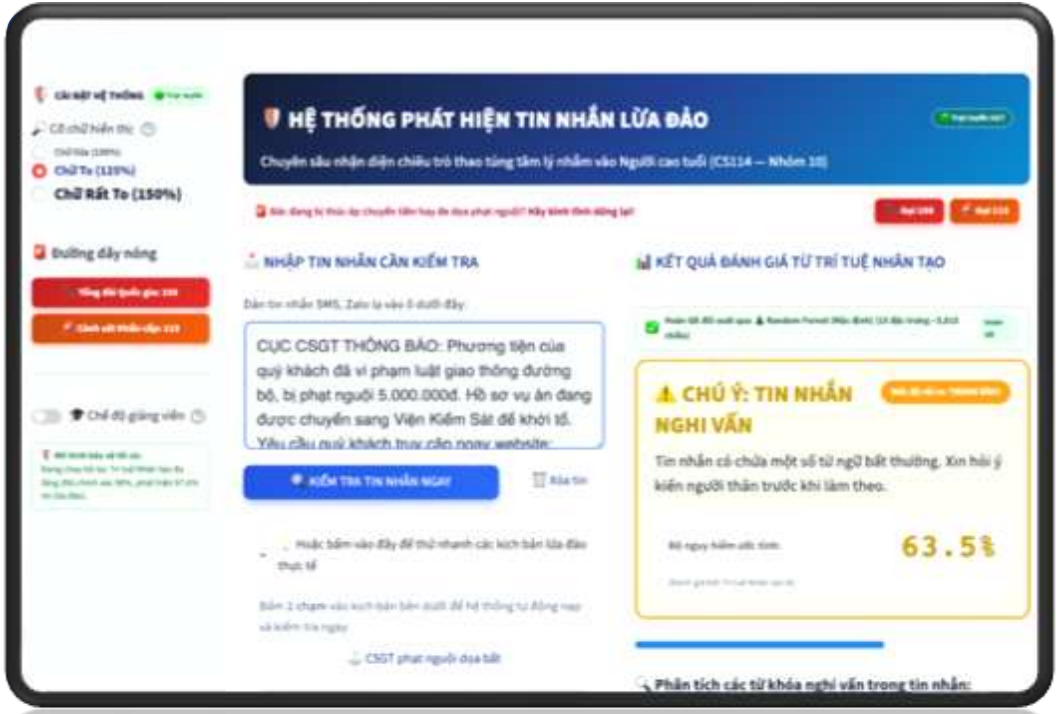
PHẦN 4

Demo Ứng dụng

- Kiến trúc ứng dụng Streamlit hỗ trợ suy luận thời gian thực với mô hình tối ưu XGBoost
- Thiết kế giao diện trợ năng chuyên biệt cho người cao tuổi: Phóng to chữ 150%, tương phản cao WCAG AA
- Tích hợp hotline khẩn cấp 156 / 113 gọi một chạm và kiểm thử toàn diện 16/16 kịch bản Playwright

Demo: Streamlit Web Application

https://cs114-team10-elderly-scam-detection.streamlit.app • Streamlit Live Demo



Giao diện phân tích tin nhắn thời gian thực với trợ năng người cao tuổi

- 4 mô hình trong 1 ứng dụng (mặc định XGBoost)
- Chỉnh cỡ chữ 100% · 125% · 150%
- Tương phản chữ 14.6:1, vượt mức WCAG 2.1 AA (4.5:1) [14]
- Hotline khẩn cấp 156 / 113 gọi 1 chạm
- Dán tin nhắn → tự động phân tích
- Trích xuất 15 đặc trưng tâm lý theo thời gian thực
- Tối ưu điện thoại · 16/16 kiểm thử E2E Playwright

PHẦN 5

Kết luận & Hướng phát triển

- Tổng kết các đóng góp chính và đối chiếu mức độ hoàn thành so với mục tiêu đề ra
- Nhìn nhận khách quan các hạn chế nghiên cứu về quy mô tập test và phân bố nhãn
- Lộ trình mở rộng: Tích hợp mô hình ngôn ngữ lớn PhoBERT và phát hiện lừa đảo qua giọng nói

Kết luận & Hướng Phát triển

Kết quả đạt được

- F1 = 95.35% (mục tiêu ≥ 88%)
- Recall = 97.62% (mục tiêu ≥ 92%)
- So sánh 4 mô hình (tối thiểu 3)
- 2.193 mẫu thực tế, Zero Synthetic Text
- SHAP XAI giải thích quyết định
- Demo thân thiện người cao tuổi

Hướng phát triển

- Tích hợp PhoBERT (BERT tiếng Việt) [15]
- Mở rộng sang lừa đảo qua giọng nói
- API cho ứng dụng ngân hàng / nhà mạng
- Mở rộng dataset lên 10.000+ mẫu
- Dashboard giám sát thời gian thực

Hạn chế đã biết: tập test chỉ có 84 tin lừa đảo (mỗi FN làm Recall đổi ~1.2 điểm); dữ liệu gộp từ nhiều nguồn ẩn danh khác kiểu thẻ — bỏ toàn bộ thẻ, F1 XGBoost 95.35% → 94.25%.

Tài liệu tham khảo

NGUỒN DỮ LIỆU

- **[1]** N. T. T. Tran et al., “Vietnamese SMS Dataset with Quality Assurance,” IEEE Access, 2026 (theo trích dẫn của tác giả; chưa có tập/DOI). GitHub: trannguyenthaituan251209/vietnamese_sms_dataset.
- **[2]** Nguồn bổ sung của tập lừa đảo (249/420 mẫu): GitHub ghitatruongle/lachancuocgoi, duynguyenhoang22/SMS_Phishing_Detection và ViSmish_Detection; báo chí, VTV24 (13 mẫu).

TIỀN XỬ LÝ NLP

- **[3]** Unicode Consortium, “UAX #15: Unicode Normalization Forms,” Unicode 18.0.0, 12 Aug. 2026.
- **[4]** V.-T. Tran, “PyVi: Python Vietnamese Toolkit,” v0.1.1. GitHub: trungtv/pyvi.
- **[5]** Underthesea NLP, “underthesea: Vietnamese NLP Toolkit,” v9.5.0. GitHub: undertheseanlp/underthesea.
- **[6]** G. Salton and C. Buckley, “Term-weighting approaches in automatic text retrieval,” Inf. Process. Manage., 24(5):513–523, 1988.

THUẬT TOÁN HỌC MÁY

- **[7]** T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” KDD 2016, pp. 785–794.
- **[8]** L. Breiman, “Random forests,” Mach. Learn., 45(1):5–32, 2001.

THUẬT TOÁN HỌC MÁY (TIẾP)

- **[9]** C. Cortes and V. Vapnik, “Support-vector networks,” Mach. Learn., 20(3):273–297, 1995.
- **[10]** J. Platt, “Probabilities for SV machines,” in Advances in Large-Margin Classifiers, MIT Press, 2000, pp. 61–74.
- **[11]** F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” JMLR 12:2825–2830, 2011.

GIẢI THÍCH MÔ HÌNH (XAI)

- **[12]** S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” NeurIPS 30, 2017.
- **[13]** S. M. Lundberg et al., “From local explanations to global understanding with explainable AI for trees,” Nat. Mach. Intell., 2(1):56–67, 2020.

TRỢ NĂNG WEB

- **[14]** W3C, “Web Content Accessibility Guidelines (WCAG) 2.1,” Recommendation, 5 Jun. 2018 (updated 6 May 2025).

HƯỚNG PHÁT TRIỂN

- **[15]** D. Q. Nguyen and A. T. Nguyen, “PhoBERT: Pre-trained language models for Vietnamese,” Findings of EMNLP, 2020, pp. 1037–1042.

Nguồn trực tuyến truy cập 21/09/2026 · [1] giấy phép CC BY 4.0 theo README · Danh sách đầy đủ 18 tài liệu: báo cáo Word

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

CHÂN THÀNH CẢM ƠN THẦY VÀ CÁC BẠN ĐÃ LẮNG NGHE BÁO CÁO!

Nhóm 10 — CS114.F31.CN2.TTNT | Tháng 09/2026

Đặng Chí Thanh · 25730067@ms.uit.edu.vn
Bùi Thị Mỷ Cẩm · 25730013@ms.uit.edu.vn
Hoàng Cao Sơn · 25730061@ms.uit.edu.vn

PHỤ LỤC

Phụ lục & Backup Q&A

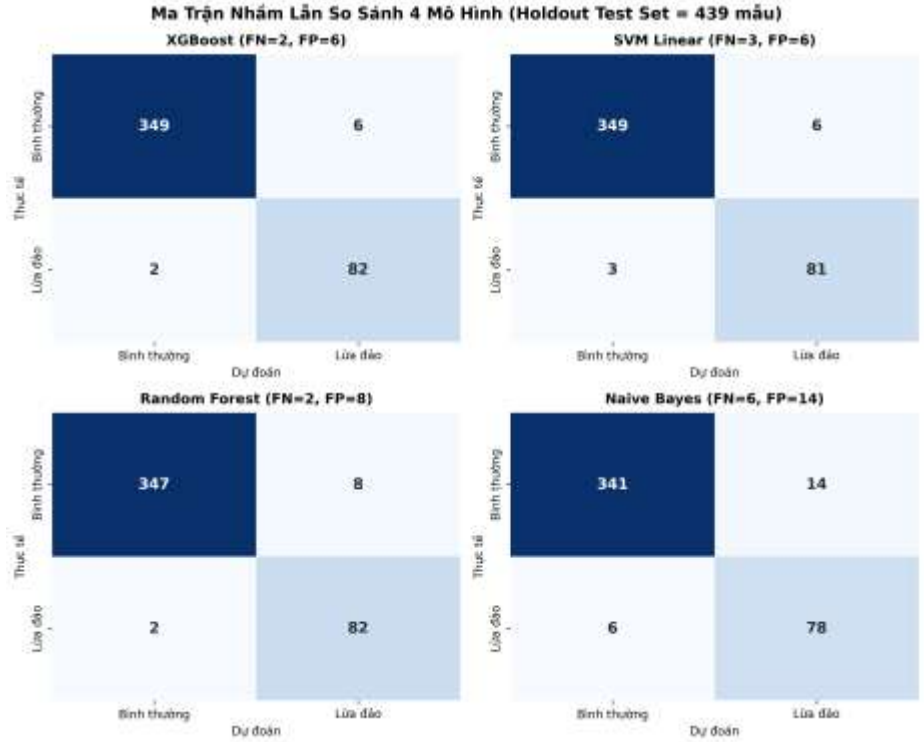
- Bảng tổng hợp chi tiết siêu tham số tối ưu và chiến lược tinh chỉnh Hyperparameter Tuning
- Phân tích chuyên sâu Ma trận Nhầm lẫn (Confusion Matrices) và đánh đổi sai số FN / FP
- Đồ thị Learning Curves: Phân tích mức độ tổng quát hóa và khoảng cách Train vs Validation

Backup: Siêu tham số & Chiến lược tinh chỉnh

Mô hình	Siêu tham số tốt nhất	Tinh chỉnh	CV F1
XGBoost	n_estimators=300, max_depth=5, learning_rate=0.05, subsample=0.7, colsample_bytree=0.8, scale_pos_weight=4.22	RandomizedSearchCV (n_iter=25, 5-fold)	0.9603
SVM Linear	C=10 (LinearSVC + CalibratedClassifierCV 5-fold)	GridSearchCV (5-fold)	0.9567
Random Forest	n_estimators=200, max_depth=50, min_samples_split=2, min_samples_leaf=2, max_features=0.2	RandomizedSearchCV (n_iter=25, 5-fold)	0.9479
Naive Bayes	alpha=0.01 (MultinomialNB) — chỉ 5.000 đặc trưng TF-IDF	GridSearchCV (5-fold)	0.9058

*Nguồn: models/*_metrics.json · CV F1 = điểm F1 trung bình cross-validation trên tập train (1.754 mẫu).*

Backup: Confusion Matrices — Cả 4 Mô hình

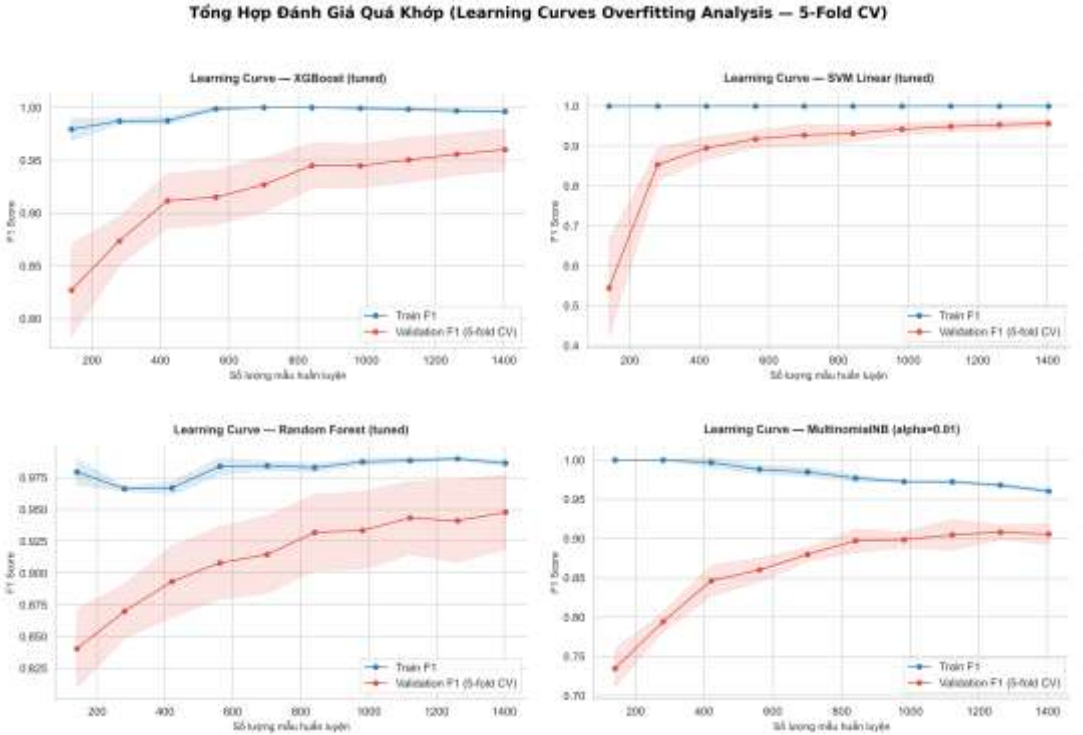


Mô hình	FN (bỏ lọt)	FP (báo sai)
XGBoost	2	6
SVM Linear	3	6
Random Forest	2	8
Naive Bayes	6	14

Cách đọc

- FN = tin lừa đảo bị bỏ lọt — nguy hiểm nhất
- FP = tin bình thường bị báo nhầm
- Tập test: 84 lừa đảo + 355 bình thường

Backup: Learning Curves — Train vs Validation



Nhận định trung thực

- Train F1 ≈ 0.96–1.0, Validation F1 ≈ 0.91–0.96 → còn khoảng cách 3–6 điểm (overfit nhẹ)
- Validation F1 của XGBoost, SVM, RF vẫn tăng theo số mẫu → thêm dữ liệu sẽ giúp
- CV F1 (~0.96) sát F1 test (0.95) → khái quát ổn